

HW05 — Performance Testing on EShop — Báo cáo chính

- **Sinh viên:** Lê Nhựt Duy — **MSSV:** 23127178
- **Môn:** Kiểm thử phần mềm (QA/QC) — **Bài:** HW05-AI Performance Testing
- **SUT:** EShop — <https://github.com/ttbhanh/eshop-sut> (backend API :3000)
- **Công cụ:** Apache JMeter 5.6.3 (mặc định §8) · k6 v2.1.0 (bonus) · Activity Monitor · Claude Code (Opus 5)
- **Máy chạy:** `Le-Nhut-Duy.local` — Apple M2 Pro, 12 lõi, 16 GB, macOS 26.1 ([hardware-report.md](#))

Quy tắc số liệu: mọi con số lấy từ [results/summary.md](#), sinh tự động bằng `npm run summary` đọc từ raw `.jtl`. Không con số nào đếm tay (§11).

Bộ số liệu chính: Load · Stress · Soak chạy ngày **15/08/2026, 15:29–16:04**, và **Spike chạy lại lúc 21:59** cùng ngày. Lý do chạy lại đúng một lượt: ảnh Spike của batch chiều **trượt đỉnh cú sốc** (bắt 34,9% trong khi đỉnh thật 81,6%), nên lượt đó được chạy lại để có ảnh khớp — lần này ảnh đọc **72,6%** so với đỉnh tool đo **75,7%**. Cả 4 lượt đều có **ảnh bằng chứng khớp timestamp**.

Các batch khác (13/08, 15/08 14:26, và lượt Spike 15:47) được **giữ lại có chủ đích**: §2.8 dùng chúng để **bác bỏ** một kết luận mà chính tôi từng đưa ra, và §3.4 dùng **bốn** lượt Spike để cho thấy phương sai giữa các lượt. Đó là hai mục đáng đọc nhất của báo cáo.

1. Phạm vi — ba endpoint group (§5)

1.1 Đăng ký của nhóm 05 và bằng chứng không trùng

§5 đòi "*ensure that your selection is not duplicated among the members of your group*". Bảng đăng ký, chốt qua chat nhóm ngày 2026-08-11:

Thành viên	Endpoint đã đăng ký
Nguyễn	POST /api/login · GET /api/products?search= · GET /api/products/:id · POST /api/cart · POST /api/checkout
Quan	GET /api/categories · GET /api/orders/my-orders · POST /api/forgot-password · POST /api/apply-coupon · PUT /api/orders/:id/cancel
Thế Đạt	POST /api/login · GET /api/categories · POST /api/categories
23127178 (bài này)	workflow admin back-office — bảng §1.2

Hệ quả: **toàn bộ luồng khách hàng** (login → search → xem chi tiết → thêm giỏ → checkout → xem/hủy đơn → áp coupon) đã bị chiếm. Đúng luồng mà đề nêu làm ví dụ — "*a virtual user may log in, browse or search products, then add an item to the cart and complete checkout*" — nằm trọn trong phần Nguyễn đã đăng ký, nên lấy lại bất kỳ đoạn nào của nó là trùng workflow theo đúng nghĩa §5 cấm.

Vì thế bài này chuyển sang **phía quản trị**: cùng phủ đủ 3 nhóm endpoint, nhưng không cắt vào luồng của ai. Chỉ `POST /api/login` giao nhau, và nó **không thể tránh** — cả 4 endpoint còn lại đều đi qua `authenticateToken`, không có token thì không đo được gì. Bản thân Nguyễn và Thế Đạt cũng đã trùng nhau ở đúng endpoint này.

(Bản đầy đủ kèm trích dẫn số dòng code: `docs/endpoint-selection.md`, nộp kèm trong `.zip` như *supporting material*.)

1.2 Workflow đã chọn

Workflow end-to-end **admin back-office**, 6 bước. Cả 4 test plan dùng **cùng** workflow này, chỉ khác tham số tải (§6 đòi đúng điều này):

Bur ớc	Endpoint	Nhóm §5	Vì sao đáng đo
1	<code>POST /api/login</code> (admin)	auth- heavy	Mỗi login thành công kèm lệnh ghi <code>UPDATE users SET login_attempts=0</code> (<code>server.js:47</code>) → endpoint auth ở SUT này không read-only
2	<code>GET /api/admin/orders</code>	read- heavy	<code>JOIN orders × users</code> , không phân trang, không index (<code>server.js:510</code>)
3	<code>GET /api/admin/users</code>	read- heavy	<code>SELECT *</code> toàn bảng (<code>server.js:494</code>)
4	<code>POST /api/admin/import-products</code>	transac tional	Bulk INSERT 3 dòng/request qua prepared statement (<code>server.js:199</code>)
5	<code>PUT /api/admin/orders/:id/status</code>	transac tional	Ghi có điều kiện qua state machine FR-10 (<code>server.js:525</code>)
6	<code>POST /api/login</code> (mật khẩu sai)	auth- heavy	Nhánh riêng 2 VU phủ account-lockout , thứ §5 nói đích danh phải tính tới

1.3 Dữ liệu data-driven (§6)

File CSV	Cột	Dùng ở bước	Số dòng
<code>data/users.csv</code>	<code>email,password,expect</code>	1	50
<code>data/users_lockout.csv</code>	<code>email,password,expect_regex</code>	6	2
<code>data/products_import.csv</code>	<code>name,price,description,category_id</code>	4	60
<code>data/orders.csv</code>	<code>order_id,next_status</code>	5	400

Mỗi VU một tài khoản riêng. Dùng chung một dòng `users` là tự tạo write-contention trên đúng dòng đó (login nào cũng `UPDATE login_attempts`) → đo ra nghẽn của cách sinh tải, không phải của endpoint.

2. Task 1 — Thiết kế và chạy

2.1 Tham số từng scenario và lý do

Scenario	VU	Ramp-up	Think-time	Thời lượng	Listener (§6: không lặp lại)	Câu hỏi scenario trả lời
Load	20	60s	$5 \times (200-600\text{ms}) = 1-3\text{s/iteration}$	360s	Summary Report	p95 ở tải kỳ vọng
Stress	bậc 25 → 50 → 100 → 200	30s mỗi bậc	$5 \times (100-200\text{ms}) = 0,5-1\text{s}$	480s	Aggregate Report	điểm gãy ở VU nào
Spike	10 nền + 200 trong 5s ở giây 60	5s	$5 \times (100-300\text{ms})$	240s	View Results Tree	bao lâu thì hồi phục
Soak	20	60s	$5 \times (200-400\text{ms}) = 1-2\text{s}$	720s	Summary Report	có trôi p95 / rò rỉ bộ nhớ

Ba điểm về tham số phải giải thích:

Think-time tính theo mỗi BƯỚC, không phải mỗi iteration. Timer ở scope thread group nên JMeter chèn nó trước **từng** sampler — 5 lần một iteration. Bản đầu đặt 1000–3000ms/bước, tức 5–15 giây một iteration, và 20 VU chỉ sinh ~10 sample/s thay vì ~50. Đã chia lại để **tổng** mỗi iteration đúng mức thiết kế.

Stress tăng theo bậc. Mục đích là tìm *điểm gãy* — mức VU nào error rate bật lên — chứ không phải chỉ biết rằng có gãy.

Spike có nhánh nền chạy xuyên suốt. Không có 10 VU nền chạy tiếp sau cú sốc thì không đo được hồi phục, chỉ thấy "lúc sốc thì chậm".

2.2 Kết quả — tổng quan

Bốn lượt tuần tự, cooldown 90s. Mốc thời gian: [results/run-log.md](#) và [endurance/run-log.md](#).

Scenario	Bắt đầu (UTC)	Sample	Peak VU	Thời lượng	RPS	Error %	avg	p50	p90	p95	p99	max
Load	08:29:38	16.343	22	359,7s	45,4	0%	3,7	3	7	8	12	84
Stress	08:37:17	258.992	200	479,9s	539,7	0%	9,6	2	8	18	124	3691
Spike	14:59:39	38.251	212	239,8s	159,5	0%	2,8	2	5	7	16	176
Soak	08:52:47	45.166	22	719,6s	62,8	0%	3,6	3	7	8	12	192

Đơn vị: **ms**. Percentile nearest-rank từ raw `.jtl`.

Điều kiện khi đo: bảng `products` ~900.000 dòng · `load_1m` trung bình **4,4–6,0** trên máy 12 lõi. Con số thứ hai là biến quan trọng nhất của cả bảng — §2.8.

Về "điểm gãy": Stress đã chạm trần, và lần này thấy rõ hơn. Ở 200 VU / 540 req/s, `node` tiêu CPU đỉnh **97,7%** — gần hết một lõi. p95 đi từ 8ms (20 VU) lên **18ms** (200 VU), p99 từ 12 lên **124ms**, và **max lên 3.691ms** — tức có request phải chờ gần 4 giây. Error vẫn 0%, nên SUT bảo hoà CPU và dẫn đuôi **trước** khi sinh lỗi. Đó là dấu hiệu điểm gãy đang ở gần, không phải dấu hiệu còn dư sức.

2.3 Kết quả theo từng endpoint

Endpoint	Load 20 VU	Stress 200 VU	Spike 212 VU	Soak 20 VU
1 POST /api/login	6	24	7	6
2 GET /api/admin/orders	9	17	7	8
3 GET /api/admin/users	6	13	5	6
4 POST /api/admin/import-products	10	22	9	10
5 PUT /api/admin/orders/:id/status	6	14	5	5
6 POST /api/login (lockout probe)	6	4	6	5

p95, đơn vị **ms**. Sample mỗi endpoint: Load ~3.250 · Stress ~51.800 · Spike ~7.600 · Soak ~9.010.

Ba điều đọc ra:

- import-products** **đắt nhất ở ba trong bốn scenario** (9–10ms), và nó là endpoint **ghi** duy nhất chạm `INSERT` thật — đúng dự đoán ở bước 1 của thiết kế: SQLite một writer.
- Ở Stress thì login vượt lên đầu (24ms)**. Login cũng ghi DB (`UPDATE users SET login_attempts=0` , `server.js:47`), và ở 200 VU với 50 tài khoản thì trung bình 4 VU cùng ghi vào một dòng `users` . Đây là chỗ p95-theo-endpoint cho thấy điều p95 tổng che mất: **thứ tự endpoint đắt nhất đổi theo mức tải**.
- p95 tổng của Stress là 18ms, nhưng login ở 24ms** — cao hơn **1,33 lần**. Một hồi quy ở login có thể không làm p95 tổng nhích lên đủ để vượt ngưỡng cảnh báo.

2.4 Human review — AI sai gì, vì sao (§6 chấm mục này)

Toàn bộ 17 lỗi kèm prompt nguyên văn: [ai-audit/ai-audit-report.md](#) . Bảy bước của quy trình thiết kế — mỗi bước hỏi gì, căn cứ nào, quyết ra sao, và **bước nào bắt được lỗi nào**: [ai-audit/design-log.md](#) .

#	AI sinh ra	Sai / thiếu ở đâu	Vì sao AI bỏ sót	Sửa thành
1	<code>preflight.mjs</code> đọc <code>java_home -V</code> từ stdout	Lệnh in ra <code>stderr</code> → báo <code>[OK]</code> Java với giá trị rong : báo xanh mà không kiểm gì	đặc điểm công cụ	hàm <code>shell()</code> gộp <code>2>&1</code> , đọc <code>os.arch</code> từ JDK
2	Nhánh lockout assert regex <code>40[13]</code>	JMeter coi mọi 4xx là Fail và assertion chỉ thêm được lỗi, không xoá được cở → smoke test báo 41,38% error trên SUT khoẻ	đặc điểm endpoint	<code>JSR223PostProcessor</code> gọi <code>prev.setSuccessful(true)</code>
3	Bước 5 assert cứng HTTP 200	FR-10 chỉ cho chuyển tiếp một lần /trạng thái → 400 là phản hồi đúng	đặc điểm endpoint	<code>assert 200 400 + reset-orders.mjs</code>
4	<code>orders.csv</code> xen kẽ <code>shipping</code>	Từ <code>pending</code> thì <code>shipping</code> không hợp lệ → nửa số sample bước 5 trả 400 ngay từ đầu	đặc điểm endpoint	chỉ sinh <code>confirmed</code>

#	AI sinh ra	Sai / thiếu ở đâu	Vì sao AI bỏ sót	Sửa thành
5	<code>users.csv</code> chứa 2 dòng mật khẩu sai	Luồng chính đọc cùng file → tự khoá tài khoản của mình ; 2,9% iteration vô giá trị	chất lượng prompt	tách <code>users_lockout.csv</code>
6	Timer 1000–3000ms ở scope thread group	Chèn 5 lần/iteration → tải thực tế nhẹ hơn 5 lần thiết kế	đặc điểm công cụ	chia lại 200–600ms/bước
7	Áp <code>mark_expected_4xx</code> cho lockout mà quên bước 5	Báo 18,25% error trên hệ thống khoẻ; 667/667 sample "lỗi" là 400 hợp lệ	suy luận không mang sang chỗ tương tự	dùng lại cùng cơ chế cho bước 5
8	<code>sample-resources.sh</code> dùng <code>pgrep -f 'node server.js'</code> \ head -1	Khớp cả tiến trình <code>zsh</code> bao ngoài → ghi RSS 0,5MB / CPU 0% suốt 6 phút	đặc điểm môi trường	lọc theo token đầu command line phải là <code>node</code>
9	Khẳng định <code>import-products</code> báo sai số dòng insert	Bác bỏ khi chạy thử : 5/5, 60/60, 2/3 đều đúng. Đã lan vào 5 file	phương pháp: suy luận từ code trình bày như sự thật đã kiểm	giữ ở mục "đã loại" kèm bảng kiểm chứng
10	<code>Math.min(...array)</code> trong summarizer	Tràn call stack với <code>.jtl</code> 264.141 sample; chạy qua bình thường ở file 16k	đặc điểm dữ liệu	thay bằng <code>reduce</code>
11	<code>mark_expected_4xx()</code> hardcoded chữ "Expected lockout response"	Dùng lại cho bước 5 mà quên đổi → raw <code>.jtl</code> ghi nhãn "lockout" cho ~50.000 sample của endpoint không liên quan gì tới lockout. Không sai số đo, nhưng là nhãn sai nằm trong bằng chứng gốc	suy luận không mở rộng — cùng loại lỗi #7	tham số hoá <code>reason</code> theo từng nhánh
12	Kết luận kích thước dữ liệu gây suy giảm p95 2,4–6,4 lần, kèm cơ chế SQLite một writer	Nhân quả rút từ một so sánh không kiểm soát biến nào. Batch sạch bác bỏ: DB lớn hơn 16 lần (50k → 830.139 dòng) mà nhẹ hơn ~10 lần . Biến tương quan mạnh nhất là <code>load_1m</code> — cũng không được gọi là nguyên nhân , vì §3.4 cho thấy nó không xếp đúng thứ tự 4 lượt Spike. Kết luận sai đã lan tới headline README , một nhánh flow chart Task 3 và một dòng self-assessment	phương pháp: nhân quả từ tương quan không kiểm soát	§2.8 viết lại thành mục thu hồi , kèm 4 cặp <code>load_1m</code>
13	<code>soak-drift.mjs</code> tính "trôi RSS" = mẫu cuối / mẫu đầu	Mẫu đầu (19,7 MB) lấy trước khi warm-up xong → in +228,9% , đọc y như một vụ rò rỉ bộ nhớ. Thực tế RSS phẳng ~78 MB suốt 12 phút; nửa đầu so nửa sau chỉ +5,0%	đặc điểm dữ liệu: chuỗi đo có warm-up ở đầu	so nửa đầu / nửa sau ; giữ dòng cũ kèm cảnh báo

#	AI sinh ra	Sai / thiếu ở đâu	Vì sao AI bỏ sót	Sửa thành
1 7	§3.4 ghi p95 đỉnh ba lượt Spike là "47 · 65 · 7ms" và quy nguyên nhân cho load_1m	Đo lại từ .jtl : 47 · 8 · 12ms. load_1m không xếp đúng thứ tự — tải nền cao nhất (6,0) cho 12ms, lượt 47ms chỉ 4,5. Số 7ms tự mâu thuẫn với bảng cửa sổ 10s ngay phía trên	bản sửa không mang sang chỗ khác: §2.8 đã thu hồi lỗi quy nhân quả này, §3.4 dùng đúng nó thì để nguyên	đo lại 3 .jtl + 3 resources; kết luận đổi thành "phương sai lớn nhất, nguyên nhân chưa biết"

12 trong 15 lỗi kỹ thuật không làm test plan báo lỗi. Plan vẫn chạy, vẫn sinh .jtl , vẫn ra dashboard đẹp — chỉ con số là sai. Nếu chỉ kiểm "test có chạy không" thì cả 12 đều lọt. Chi phí thật: **hai lượt chạy phải huỷ và xoá sạch bằng chứng**, ~25 phút chạy lại.

Phân bố ba nhóm lý do §6 yêu cầu phân loại lệch hẳn về một phía: **7 lỗi là đặc điểm công cụ/endpoint/môi trường/dữ liệu**, 1 là chất lượng prompt, **3 là phương pháp** (#9, #12, #13), 2 là *suy luận đúng nhưng không mang sang chỗ tương tự* (#7 và #11 — cùng một cơ chế, sai hai lần), và **không lỗi nào** thuộc "model không đủ khả năng". Điểm yếu không nằm ở chỗ AI không biết viết test plan, mà ở chỗ nó **không chạy thử và không đối chiếu với thực tế**.

Một con số đáng chú ý riêng: **3 trong 15 lỗi kỹ thuật nằm trong chính tooling đo** (#1 preflight, #8 sample-resources, #13 soak-drift) — gần **1/4 số lỗi đến từ dụng cụ đo, không từ hệ thống được đo. Đó là lý do §6 của bài này đối chiếu chéo số của tool tự viết với ảnh Activity Monitor thay vì tin một nguồn duy nhất (§2.5).

Hai lỗi nữa không nằm trong bảng, vì chúng không làm sai con số nào — chúng làm sai bản nộp, và cả hai do tôi bắt, không phải AI tự soát ra: (14) bằng chứng §5 chỉ nằm trong docs/ là folder **không có trong danh sách §14** → yêu cầu có bằng chứng đủ mà người chấm không đọc được, §17 tính 0 điểm cho mục đó, đã chép vào **§1.1** của chính báo cáo này; (15) lỗi ở §2 "step by step" được AI **tự ghi ra rồi để nguyên**, coi thừa nhận hạn chế là đã xử lý hạn chế, đã bịt bằng ai-audit/design-log.md . Tính cả hai: **2 trong 17 lỗi của cả bài là do người bắt** — và đó đúng là hai lỗi **không script nào phát hiện được**, vì không có gì sai về mặt kỹ thuật để mà báo.

2.5 Bảng chứng chạy

Scen ario	Test plan	Raw .jtl được nộp làm số chính	HTML dashboard	Ảnh §6
Load	23127178_Load_20260813.jmx	results/jtl/23127178_Load_20260815-152938.jtl	results/html/load/	activity-load.png — 13,4%
Stress	23127178_Stress_20260813.jmx	results/jtl/23127178_Stress_20260815-153717.jtl	results/html/stress/	activity-stress.png — 91,7%
Spike	23127178_Spike_20260813.jmx	results/jtl/23127178_Spike_20260815-215939.jtl	results/html/spike/	activity-spike.png — 72,6%
Soak	23127178_Soak_20260813.jmx	endurance/jtl/23127178_Soak_20260815-155240.jtl	endurance/html/soak/	activity-soak.png — 16,3%

Ảnh: đủ 4 lượt + 1 ảnh spec máy, ở resource-monitor/screenshots/ . Cột cuối là số node CPU được được trong ảnh; đối chiếu với đỉnh do tool đo ở bảng dưới.

Mốc thời gian từng ảnh chốt trong `resource-monitor/screenshots/manifest.json` — mỗi ảnh có `sha256` + `captured_at` + lượt chạy tương ứng + **offset giây** tính từ lúc lượt bắt đầu. Kiểm bằng `npm run verify` mục 4.

Vì sao chốt vào manifest chứ không đọc `mtime`: `package.sh` copy bằng `cp -R`, và `cp` **đặt `mtime` mới** cho bản copy — chạy validator bên trong `.zip` sẽ báo đỏ toàn bộ dù ảnh hoàn toàn thật. `sha256` là phần làm manifest có giá trị: nếu chỉ ghi giờ thì sửa một dòng JSON là xong.

Một chi tiết phải nói ra, vì §11 chấm đúng chỗ này: `activity-stress.png` có giờ lưu **sau khi lượt Stress kết thúc vài giây**. `Cmd+Shift+4` ghi file lúc **nhả chuột**, nên giờ lưu luôn trễ hơn khoảng khắc trong khung. Bằng chứng khung hình đúng là trong lượt nằm ở **nội dung ảnh**: nó đọc `node` **91,7%**, chỉ có ở bậc 200 VU, còn sau khi lượt kết thúc thì `node` về dưới 5%. Manifest ghi nhận ảnh này là *lưu sau lượt* thay vì để nó lặng lẽ đậu ở biên.

Đường đi tới bộ ảnh này, vì §11 chấm bằng chứng có thật: lần chụp đầu dùng `screencapture` toàn màn hình và bắt được cửa sổ đang ở trước (VS Code của một project khác, một lần là Mission Control) chứ không phải JMeter + Activity Monitor. Những ảnh đó **vô giá trị** làm bằng chứng §6 nên đã bị xoá, kể cả khỏi lịch sử git. Cách làm đúng và đã dùng: **sinh viên tự chạy `npm run capture` trong Terminal của mình**, script đếm ngược tới mốc cần chụp, và vì §6 đòi chụp **trong lúc** lượt chạy diễn ra nên 4 lượt đã được chạy lại. Riêng Spike phải chạy lại lần nữa lúc 21:59 vì ảnh đầu trượt đỉnh cú sốc (34,9% trong khi đỉnh thật 81,6%).

Bằng chứng tài nguyên **dạng số** thì có đầy đủ và tính toán được — `results/resources/*.csv` và `endurance/resources/*.csv`, lấy mẫu 2 giây/lần cho cả `node` và JMeter:

Scenario	load_1m tb	node CPU đỉnh	JMeter CPU đỉnh	node RSS đỉnh
Load	4,4	20,3%	118,3%	81,1 MB
Stress	5,7	97,7%	178,3%	1373,2 MB
Spike	3,3	75,7%	205,2%	90,0 MB
Soak	4,6	23,6%	49,3%	83,1 MB

Ba điều trong bảng này quan trọng hơn bảng p95:

- 1. `node` CPU 97,7% ở Stress** — gần hết một lõi. Ảnh `activity-stress.png` bắt được đúng khoảnh khắc đó ở **91,7%**, xem được bằng mắt trong Activity Monitor.
- 2. JMeter tiêu CPU nhiều hơn `node` ở cả 4 lượt** (118–183% so với 20–98%). Load generator và SUT tranh cùng số lõi, nên một phần latency đo được là chi phí của chính JMeter. Đây là giới hạn #2 ở §6.
- 3. RSS `node` vọt lên 1373 MB ở Stress** rồi về ~21 MB. Chỉ **2 mẫu trên 230** vượt 500 MB, tức một đỉnh nhọn dưới 4 giây. Lượt Stress ở batch 14:26 cùng ngày đỉnh chỉ **98 MB**. Tôi **không** kết luận nguyên nhân: một đỉnh nhọn trên hai mẫu là quá ít để loại được ba giả thuyết (page cache SQLite khi `import-products` chạy · hàng đợi request tích tụ ở 200 VU · nhiễu đo). Ghi lại như một **quan sát chưa giải thích được**, và nếu cần trả lời thì phải chạy Stress nhiều lần ở cùng `load_1m` rồi xem đỉnh đó có lặp lại.

2.6 Xử lý account-lockout và state machine giữa các lượt (§6 đòi ghi lại)

```
npm run reset:lockout      # UPDATE users SET login_attempts=0, locked_until=NULL
npm run reset:orders       # UPDATE orders SET status='pending'
```

`tools/run-scenario.sh` tự chạy cả hai ở đầu mỗi lượt và in trạng thái trước/sau.

Lockout kích hoạt sau 2 lần sai, không phải 3 — `login_attempts + 2` với ngưỡng 3 (`server.js:54-58`), khoá 180 giây.

Scenario	bước 6: 401 (sai lần đầu)	bước 6: 403 (đã khoá)	bước 5: 200 (ghi thật)	bước 5: 400 (FR-10 chặn)
Load	4 (4,2%)	91 (95,8%)	400 (12,3%)	2.841 (87,7%)
Stress	4 (4,3%)	90 (95,7%)	400 (0,8%)	51.301 (99,2%)
Spike	4 (4,2%)	91 (95,8%)	400 (5,3%)	7.129 (94,7%)
Soak	4 (4,3%)	90 (95,7%)	400 (4,4%)	8.609 (95,6%)

Hai con số lặp lại **y hệt qua cả 4 lượt** là bằng chứng reset hoạt động đúng:

- **Đúng 4 lần 401** mỗi lượt = 2 tài khoản × 2 lần sai trước khi bị khoá. Nếu reset không chạy, lượt sau sẽ bắt đầu bằng `403` ngay và con số 4 này biến mất.
- **Đúng 400 lần 200** ở bước 5 = số dòng `orders.csv` . Mỗi order chuyển được đúng một lần `pending → confirmed` . Nếu `reset-orders.mjs` không chạy, con số này sẽ là 0.

Từ lượt chạy này, cột `responseMessage` trong raw `.jtl` ghi đúng lý do cho từng loại: `FR-10 invalid transition` (hop le) cho bước 5 và `Account lockout` (hop le) cho bước 6 — trước đó cả hai đều ghi "lockout", xem lỗi #11.

Giới hạn của phép đo ở bước 5: nhánh 400 trả về **trước** lệnh `UPDATE` nên nhẹ hơn nhánh 200. Ở lượt Stress chỉ 0,7% sample chạm tới lệnh ghi thật, nên p95 5ms của bước 5 **không** đại diện cho chi phí ghi. Tín hiệu ghi nặng nằm ở **bước 4**.

2.7 Endurance threshold (§6)

Chi tiết: `endurance/endurance-threshold.md` .

Định nghĩa "ổn định" chốt **trước** khi chạy: *error rate < 1% và p95 không tăng quá 20% giữa 5 phút đầu và 5 phút cuối.*

Chỉ số	Giá trị
Thời lượng soak	719,6s (12 phút) · 45.166 sample
Nhịp đã xác nhận bền được (không phải "tối đa")	62,8 req/s ở 20 VU
p95 toàn lượt	8 ms · p99 12 ms
p95 5 phút đầu → cuối	8 ms → 8 ms (+0%)
Error rate	0%
RSS nửa đầu → nửa sau	74,5 → 78,3 MB (+5,0% — đi ngang)

Chỉ số	Giá trị
Trần bộ nhớ (RSS đỉnh)	83,1 MB
CPU node đỉnh	23,6%
Kết luận	ỔN ĐỊNH theo đúng định nghĩa đã chốt

Một con số tôi phải tự sửa ở đây. Tool `soak-drift.mjs` ban đầu in "*Trôi RSS +228,9%*" — vì nó so **mẫu đầu tiên với mẫu cuối cùng**, mà mẫu đầu (19,7 MB) lấy lúc process chưa warm-up xong. Đọc con số đó thì kết luận "có rò rỉ bộ nhớ". Sự thật: RSS leo lên ~78 MB trong 60 giây ramp-up rồi **phẳng suốt 12 phút** — nửa đầu 74,5 MB, nửa sau 78,3 MB, chênh **+5,0%**. Đã sửa tool để so nửa-đầu/nửa-sau; ghi thành lỗi #13 trong AI audit.

2.8 Một phát hiện tôi đã tự bác bỏ — và biến số thật hiện ra sau ba lượt

Bản báo cáo trước của chính tôi có một mục mang tên "*phát hiện quan trọng nhất của bài*": so hai batch chạy cách nhau hai ngày, thấy p95 chênh **2,4–6,4 lần**, và kết luận rằng **kích thước dữ liệu phình lên** là nguyên nhân — kèm cơ chế nghe rất hợp lý (SQLite một writer, INSERT chậm hơn tạo hàng đợi mà cả endpoint đọc cũng phải xếp sau).

Kết luận đó sai. Ba batch cùng test plan, cùng máy, cho ba kết quả khác nhau:

Batch	products trong DB	load_1m tb (Stress)	p95 Stress
13/08	~50.000	5,2	26 ms
15/08 14:26	~830.000	3,1	7 ms
15/08 15:37 (<i>bộ nộp</i>)	~900.000	5,7	18 ms

Đọc theo cột dữ liệu: 50k → 830k → 900k, tức **tăng đơn điệu**. Nếu dữ liệu là nguyên nhân thì p95 phải tăng theo. Thực tế p95 đi **26 → 7 → 18 ms** — không theo dữ liệu chút nào.

Đọc theo cột `load_1m`: **5,2 → 3,1 → 5,7**, và p95 đi **26 → 7 → 18**. Cùng chiều, cả ba điểm.

Biến số thật là **tải nền của máy**. Lúc đo vẫn có 4 container Docker (`postgres` , `redis` , `qdrant` , `adminer`), VS Code, Chrome và một tiến trình AI agent chạy song song.

Sai ở chỗ nào, gọi tên chính xác: ở bản đầu tôi chỉ có **hai** điểm dữ liệu và chúng khác nhau ở **nhiều biến cùng lúc** (thời điểm, tải nền, kích thước dữ liệu, cả bug sampler ở lỗi #8). Tôi chọn một biến mình thấy thú vị, gán toàn bộ chênh lệch cho nó, và viện một cơ chế đúng-về-lý-thuyết làm chỗ dựa. Cơ chế đúng **không** chứng minh được nó là nguyên nhân của con số cụ thể này — hai việc khác nhau, và tôi đã trộn chúng.

Điểm thứ ba là thứ đã cứu: nó phá vỡ tương quan giả với kích thước dữ liệu, đồng thời **giữ nguyên** tương quan với `load_1m` . Một điểm dữ liệu nữa đôi khi rẻ hơn nhiều một lập luận hay.

Mức độ lan của lỗi: kết luận đó từng là **headline của README**, một **nhánh trong flow chart Task 3**, và một dòng **tự đánh giá** khoe rằng bài tự chỉ ra lỗi hổng của chính nó bằng số đo. Cả ba đã được sửa.

Kết luận thay thế, kiểm chứng được bằng ba cặp số ở bảng trên:

Trên máy cá nhân dùng chung với công việc khác, `load_1m` là **biến tương quan mạnh nhất trong ba điểm dữ liệu này** — chưa đủ để gọi là nguyên nhân. Nó chênh 1,8 lần (3,1 → 5,7) trong khi p95 chênh **2,6 lần**; để so sánh, tăng số VU **gấp 10 lần** (20 → 200) chỉ làm p95 đi từ 8 lên 18 ms, tức **2,25 lần**.
Điều nói được: **nhiều môi trường lớn hơn tín hiệu mình chủ động tạo ra.**

Vì sao không gọi `load_1m` là nguyên nhân, dù rất muốn. Ba điểm dữ liệu, không có lượt nào **giữ mọi biến khác cố định rồi chỉ đổi tải nền** — tức vẫn là *tương quan*, đúng loại lập luận mà mục này đang thu hồi. Và có bằng chứng ngược ngay trong bài: ở §3.4, bốn lượt Spike có `load_1m` 4,5 / 2,2 / 6,0 / 3,3 nhưng p95 đỉnh **47 / 8 / 12 / 9 ms** — **không xếp đúng thứ tự**. Nếu tải nền là nguyên nhân chi phối thì thứ tự đó phải đúng. Nó không đúng.

Phát biểu chịu được chất vấn: **tải nền đủ lớn để làm mọi so sánh giữa hai lượt trở nên vô nghĩa nếu không kiểm soát nó** — và thế là đủ cho mọi kết luận bài này cần. Nguyên nhân đầy đủ thì **chưa biết**, và cách kiểm là chạy lại cùng cấu hình ở nhiều mức `load_1m` khác nhau, việc bài này chưa làm.

Hệ quả trực tiếp cho Task 3 — xem §4.3, mục "*Nhiều áp đảo tín hiệu*".

Còn câu hỏi kích thước dữ liệu thì sao? Vẫn là câu hỏi mở, và bài này **không trả lời được**. Ba lượt đều không cô lập được biến đó. Muốn trả lời thì phải giữ `load_1m` cố định, snapshot DB ở hai kích thước, chạy cùng plan hai lần. Đó là phép đo tôi chưa làm, và ghi nó vào phần "chưa làm" trung thực hơn là giữ một kết luận không đứng được.

3. Task 2 — AI phân tích và soát lỗi đọc metric

3.1 Phân tích của AI (nguyên văn, chưa sửa)

Kết quả tốt. Cả bốn scenario 0% error. Stress đạt **540 RPS với p95 18ms** — backend xử lý 200 người dùng đồng thời tốt, chỉ chậm hơn 2 lần so với 20 người (8ms). Average 9,6ms. Soak 12 phút không rò rỉ bộ nhớ (RSS 19,7 → 64,8 MB là bình thường). So với batch trước p95 tăng từ 7 lên 18ms, có thể do database đã lớn hơn. Đề xuất ngưỡng: p95 < 50ms, error < 1%. Hệ thống đạt yêu cầu.

3.2 Soát lại — chỗ AI đọc sai metric

#	AI nói	Giá trị đúng từ raw .jtl / resources	Sai ở đâu
1	"p95 tăng từ 7 lên 18ms, có thể do database đã lớn hơn"	DB tăng từ ~830k lên ~900k dòng (+8%), nhưng <code>load_1m</code> tăng từ 3,1 lên 5,7 (+84%). Ba batch: <code>load_1m</code> 5,2/3,1/5,7 → p95 26/7/18	Lỗi nặng nhất, và là đúng lỗi tôi từng tự mắc (§2.8). Chênh 2,6 lần p95 không thể do dữ liệu tăng 8%. AI chọn giả thuyết nghe hợp lý thay vì đọc cột <code>load_1m</code> trong file resources mà chính bộ tool này đã ghi ra
2	"backend xử lý 200 người dùng đồng thời tốt"	p95 8 → 18ms là đúng, nhưng node CPU đi từ 20,3% → 97,7% (<code>results/resources/23127178_Stress_20260815-153717.resources.csv</code>)	Đọc p95 mà bỏ CPU thì kết luận ngược. Server giữ được p95 bằng cách dùng gần hết một lõi , tức đang sát trần chứ không "tốt"

#	AI nói	Giá trị đúng từ raw .jtl / resources	Sai ở đâu
3	"Average 9,6ms"	avg 9,6 nhưng p99 124ms , max 3691ms	p99 gấp 12,9 lần avg, max gấp 384 lần . Có request phải chờ gần 4 giây . Ở lượt Load tỉ lệ p99/avg chỉ 3,2 — nghĩa là đuôi dẫn theo tải , và average xoá sạch điều đó
4	"Cả bốn scenario 0% error"	Đúng, nhưng 99,2% sample bước 5 ở Stress trả 400 , và 95,7% bước 6 trả 403	0% đúng nhờ test plan đã sửa để coi hai loại 4xx đó là hợp lệ. Chỉ 0,8% request bước 5 chậm tới lệnh ghi thật
5	"RSS 19,7 → 64,8 MB là bình thường"	Kết luận đúng nhưng lập luận rỗng . Số đúng để dùng: nửa đầu 74,5 → nửa sau 78,3 MB = +5,0%	AI lấy đúng cặp số mà tool của tôi in ra sai (mẫu đầu chưa warm-up). Nó không kiểm lại, chỉ gắn chữ "bình thường". Trùng hợp đúng kết luận không phải là phân tích — xem lỗi #13
6	"Đề xuất ngưỡng p95 < 50ms"	p95 đo được 18ms	Ngưỡng rộng gấp 2,8 lần giá trị hiện tại → không phát hiện được hồi quy nào cho tới khi hệ thống xấu đi gần 3 lần. Ngưỡng hồi quy phải tương đối (+20% so với baseline), không phải một số tuyệt đối chọn cho dễ đạt
7	"Hệ thống đạt yêu cầu"	node CPU 97,7%; max 3691ms	Đạt yêu cầu nào ? Không có SLA nào được nêu trước. Kết luận "đạt" khi chưa có ngưỡng là kết luận rỗng

Điểm chung: sáu trong bảy lỗi đến từ việc **đọc một metric mà bỏ metric đi kèm** — p95 mà bỏ CPU, average mà bỏ p99, error rate mà bỏ phân bố response code, chênh lệch giữa hai lượt mà bỏ `load_1m` . Không lỗi nào do đọc sai con số; tất cả do đọc **thiếu** con số.

3.3 Đề xuất tối ưu của AI — feasible hay hallucinated

Đề xuất	Phân loại	Lý do	Cách kiểm chứng
"database đã lớn hơn" (giải thích chênh lệch)	hallucinated	DB tăng 8%, <code>load_1m</code> tăng 84%. AI bịa nguyên nhân cho hiện tượng nó không đo	—
"hệ thống đạt yêu cầu, không cần tối ưu"	Sai	<code>node</code> CPU 97,7% ở 200 VU, max 3691ms	Đẩy quá 200 VU ở <code>load_1m</code> thấp, xem error bật lên ở đâu
Bật SQLite WAL	feasible	Đúng loại tải: bước 4 ghi 3 dòng/request, bước 1 ghi 1 dòng/login. Một dòng <code>PRAGMA journal_mode=WAL</code>	Chạy lại Stress ở cùng <code>load_1m</code> , so p95 của <code>import-products</code> và <code>login</code>
Thêm index cho <code>orders.user_id</code>	feasible	<code>GET /api/admin/orders</code> JOIN theo <code>user_id</code> , không index	<code>CREATE INDEX</code> rồi chạy lại, so p95 đúng label đó
Connection pool cho SQLite	hallucinated	<code>sqlite3</code> của Node mở handle trên file cục bộ, không phải client-server	—
Scale ngang / replica	hallucinated trong phạm vi bài	SUT là một process trên máy cá nhân	—

Bốn đề xuất của tôi mà AI không nêu:

- 1. Chạy `node` với cluster / nhiều worker. Căn cứ mạnh nhất từ số liệu: CPU chạm 97,7% của một lõi trong khi máy còn **11 lõi rảnh**. Trần hiện tại là trần một-luồng, không phải trần phần cứng.

2. **Kiểm soát tải nền khi đo.** §2.8: tương quan mạnh nhất đo được. Không có nó thì mọi so sánh giữa hai lượt đều vô nghĩa — kể cả so sánh của chính bài này.
3. **Dọn dữ liệu test sau mỗi lượt.** Bộ test tự đẩy `products` từ 5 dòng lên ~900.000. Để một biến trôi không kiểm soát qua các lượt là lỗi thiết kế của bộ test.
4. **Điều tra đỉnh RSS 1373 MB ở Stress (§2.5)** — chưa giải thích được, và một đỉnh 1,4 GB trên một process bình thường ở 21 MB thì đáng đào tiếp.

3.4 Đo hồi phục sau cú sốc (Spike)

p95 theo cửa sổ 10 giây quanh cú sốc ở giây 60, **lượt nộp** (`results/jtl/23127178_Spike_20260815-215939.jtl`), kèm cột cuối là cùng cửa sổ đó ở lượt 15:47 để đối chiếu:

Giây	VU	Sample	p95	p99	(p95/p99 lượt 15:47)
40–50	12	485	7	10	9 / 18
50–60	19	503	8	10	8 / 10
60–70	212	7.885	5	9	7 / 46
70–80	212	10.231	7	20	8 / 22
80–90	212	10.121	7	18	7 / 15
90–100	12	482	8	14	12 / 52
100–110	12	501	6	8	6 / 10

Trong lượt được nộp, không quan sát thấy suy giảm nào khi cú sốc dội vào. VU nhảy từ 12 lên **212 trong 5 giây**, sample/10s tăng từ ~500 lên **10.231 (gấp 20 lần)**, mà p95 **giảm** nhẹ xuống 5–7ms so với 7–8ms lúc nền. Không có 5xx, không timeout.

Phát biểu này cố ý bị giới hạn ở một lượt. Nói "server hấp thụ trọn cú sốc" là một phát biểu về **hệ thống**, và bốn lượt Spike không cho phép nói thế: một lượt có p95 đỉnh cửa sổ **47ms** (bảng dưới). Cái đo được là *lượt này không suy giảm*, không phải *hệ thống luôn hấp thụ được*.

Một "phát hiện" của bản báo cáo trước, và nó không lặp lại được. Ở lượt 15:47, cửa sổ **90–100s** — lúc **tải rút đi** — cho p95 **12ms** và p99 **52ms**, cao hơn cả lúc đang chịu 212 VU. Báo cáo gọi đó là điều thú vị nhất của mục này và giải thích bằng chi phí **tear-down**: 200 thread JVM đóng kết nối cùng lúc, `node` phải dọn 200 socket trong khi 12 VU nền vẫn gửi request.

Lượt 21:59 **không cho hiện tượng đó**: cùng cửa sổ 90–100s chỉ p95 **8ms** / p99 **14ms**, tức nhích 1ms so với lúc chịu tải — trong ngưỡng nhiễu. Cơ chế tear-down vẫn **hợp lý về lý thuyết** và vẫn có thể đúng, nhưng **một lượt không chứng minh được nó**, và đúng bằng chứng để nói thế nằm ngay trong mục này: bốn lượt Spike lệch nhau 5,9 lần ở p95 đỉnh (bảng dưới). Giữ lại cả hai cột thay vì im lặng thay số, vì chỗ này là ví dụ gọn nhất cho toàn bộ luận điểm §3.4 — **một quan sát đơn lẻ trên một lượt Spike không phải là một phát hiện**.

Ba lượt Spike cho ba kết quả khác nhau, và không biến nào giải thích được thứ tự đó. Đo lại p95 đỉnh của cửa sổ 10 giây trên cả ba `.jtl`, kèm `load_1m` trung bình lấy từ file resources tương ứng:

Lượt Spike	Sample	p95 đỉnh cửa sổ	load_1m tb	node CPU đỉnh
13/08 13:29	38.069	47 ms	4,5	78,9%

Lượt Spike	Sample	p95 đỉnh cửa sổ	load_1m tb	node CPU đỉnh
15/08 14:44	38.388	8 ms	2,2	76,1%
15/08 15:47	38.160	12 ms	6,0	81,6%
15/08 21:59 (bộ nộp)	38.251	9 ms	3,3	75,7%

Chênh lệch **5,9 lần** giữa lượt cao nhất và thấp nhất, trong khi số sample chỉ lệch **0,8%** — cùng một lượng công việc, bốn kết quả. **load_1m không xếp đúng thứ tự**: lượt tải nền **cao nhất** (6,0) cho **12ms**, còn lượt cho **47ms** chỉ ở 4,5, và lượt 3,3 cho 9ms. Nếu tải nền là nguyên nhân thì thứ tự phải là $2,2 < 3,3 < 4,5 < 6,0 \rightarrow 8 < 9 < 47 < 12$, và nó không phải vậy.

Cột cuối là chỗ đáng đọc nhất của bảng. node CPU đỉnh gần **nhau** ở **cả bốn lượt** — 75,7 / 76,1 / 78,9 / 81,6%, lệch **4 điểm phần trăm** — trong khi p95 đỉnh lệch **5,9 lần**. Nghĩa là server làm **đúng lượng việc như nhau** mỗi lượt; cái nhảy 5,9 lần **không** nằm ở lượng công việc mà ở **thứ tự chờ**: request nào rơi vào đúng lúc CPU bị tiến trình khác chen ngang thì phải xếp hàng, và p95 đọc đúng cái xếp hàng đó. Đây là lý do một lượt Spike đơn lẻ **không** dùng làm baseline được, kể cả khi CPU nhìn hoàn toàn bình thường.

Bản trước của mục này ghi "47 · 65 · 7ms" và quy nguyên nhân cho load_1m . Hai con số sai và lập luận không đứng được. Đây là **lỗi #17**: §2.8 đã thu hồi việc quy nhân quả cho một biến đơn lẻ, nhưng chỗ này — cũng dùng đúng lập luận đó — thì để nguyên. **Sửa một chỗ mà không mang bản sửa sang mọi chỗ đã dùng lập luận cũ.** Con số 7ms còn tự mâu thuẫn với chính đoạn trên: bảng cửa sổ 10s ngay phía trên ghi cửa sổ 90–100s là **12ms**.

Kết luận đứng được, và nó **không** cần tới **load_1m**: **spike test là loại có phương sai lớn nhất giữa các lượt**, vì nó đọc phản ứng trong một cửa sổ chỉ 30 giây — nơi một sự kiện ngẫu nhiên bất kỳ trên máy là đủ đổi con số. Điều gì gây ra thì bài này **chưa biết**, và ghi đúng là chưa biết.

Kết luận đó có **thêm một hậu thuẫn độc lập** ở §4.4: ba lượt CI **giống nhau từng tham số**, trên runner sạch, cho p95 **101 / 15 / 8ms** — lệch 12,6 lần. Hai nền tảng khác nhau, cùng một hiện tượng. Vì thế **không** được dùng một lượt Spike đơn lẻ làm baseline, và đó là căn cứ cho nút I của flow chart §4.

Đây cũng là chỗ **View Results Tree** phát huy: mở các sample chậm nhất trong cửa sổ 60–70s cho thấy chúng là `POST /api/login` — khớp với việc login phải khởi tạo 200 kết nối mới cùng lúc.

3.5 Chi phí của load generator — và vì sao k6 vẫn chỉ là bản mirror (bonus §8)

Load generator tốn CPU nhiều hơn cả hệ thống đang được đo. Ở lượt Stress được nộp (23127178_Stress_20260815–153717), JMeter CPU đỉnh **178,3%** so với node **97,7%** — tức **1,8 lần**. JMeter cấp một **thread JVM** cho mỗi VU, nên ở 200 VU nó ngốn 844 MB RSS và gần hai lõi chỉ để *sinh* tải.

Hệ quả trực tiếp lên cách đọc mọi số p95 của bài: load generator và SUT **dùng chung 12 lõi**, nên một phần latency đo được là **thời gian JMeter tự chờ chính nó**, không phải thời gian server xử lý. Không tách được phần đó ra bằng dữ liệu đang có.

Và chính tỉ lệ này cũng **không ổn định giữa các lượt** — thêm một trường hợp của §3.4:

Lượt Stress	node CPU đỉnh	JMeter CPU đỉnh	Tỉ lệ
15/08 14:34	98,4%	106,2%	1,08×
15/08 15:37 (nộp)	97,7%	178,3%	1,83×

Cùng plan, cùng số VU, cùng máy: SUT tiêu CPU **như nhau** (98,4 vs 97,7%) trong khi load generator lệch **1,7 lần**. Bản báo cáo trước trích cập số của lượt 14:34 rồi viết "*hai bên xấp xỉ nhau*" — đúng với lượt đó, **sai với lượt được nộp**, và không nói đang trích lượt nào.

k6 để làm gì. Bản mirror dùng **cùng** workflow và cùng CSV: [k6/](#). k6 dùng goroutine thay vì thread JVM, nên nó là cách kiểm giả thuyết "một phần latency là chi phí của JMeter": nếu cùng workflow mà k6 cho p95 thấp hơn ở cùng `load_1m`, phần chênh đó là chi phí generator.

```
k6 run --summary-export k6/summary-stress.json k6/stress.js
```

Chưa chạy lần nào. §8 xếp k6 là bonus và bản JMeter là bản chính theo §14, nên bài này **không** khẳng định đã đối chiếu chéo — chỉ nêu phép kiểm và điều kiện của nó: phải chạy ở **cùng mức load_1m** mới so được, theo đúng bài học §2.8. Nói "đã đối chiếu chéo" khi chưa chạy thì đúng là loại khẳng định mà cả Task 2 của bài này đang đi soát.

4. Task 3 — Đề xuất Continuous Performance Testing

4.1 Mô hình

```

flowchart TD
    A[Commit vào SUT] --> B{Diff có chậm<br/>backend/ hay database.js?}
    B -- không --> Z[Bỏ qua perf test]
    B -- có --> C{Loại commit?}
    C -- hotfix/docs --> D[Chỉ smoke perf 60s]
    C -- feature/refactor --> E[Load test rút gọn 3 phút]
    E --> F[So p95 từng endpoint<br/>với baseline nhánh main]
    D --> F
    F --> G{p95 tăng > 20%<br/>ở ≥1 endpoint?}
    G -- không --> H[Cập nhật baseline · pass]
    G -- có --> I{Lặp lại được<br/>sau 2 lượt chạy?}
    I -- không --> J[Nhiều – ghi log, không cảnh báo]
    I -- có --> K[Chặn PR + cảnh báo kèm<br/>link .jtl và dashboard]
    H --> L{Lịch hàng tuần?}
    L -- có --> M[Chạy lại baseline main + PR<br/>trên CÙNG runner, CÙNG lượt CI]
    M --> N{Chênh p95 > 20%<br/>giữa hai lần đo?}
    N -- có --> O[Nghi runner nhiều –<br/>không chặn PR, ghi log]
  
```

Nhánh `L → O` **được viết lại sau khi §2.8 bị bác bỏ**. Bản trước là "chạy Stress hàng tuần trên snapshot DB đã phình" — dựa trên một kết luận đã sai. Bản này giải quyết vấn đề **thật sự** đo được: nhiều từ máy chạy.

4.2 Giải thích từng nhánh quyết định

B — lọc theo phạm vi diff. Perf test chỉ chạy khi diff chạm `backend/` hoặc `database.js`. Quyết định về chi phí: SUT có 4 ứng dụng, phần lớn commit sửa frontend, một lượt perf test đầy đủ mất ~30 phút CI.

C — phân loại commit. `hotfix / docs` chỉ smoke 60 giây. `feature / refactor` chạy Load rút gọn 3 phút — vẫn qua được ramp-up và vào trạng thái ổn định.

F — so baseline theo TỪNG endpoint. Ở batch này p95 tổng (7ms) **trùng** p95 của endpoint đắt nhất, tức không có hiệu ứng pha loãng — nhưng **chỉ biết được điều đó bằng cách xem theo endpoint**. Batch 13/08 thì có pha loãng thật (p95 tổng 26ms trong khi login 40ms). Không thể giả định trước là số tổng đại diện được.

G — ngưỡng 20%. Lấy đúng ngưỡng của định nghĩa "ổn định" ở endurance test, để cả hệ thống chỉ có **một** định nghĩa hồi quy.

I — đòi lặp lại được. Bộ lọc báo động giả quan trọng nhất: p95 trên runner ảo dao động theo tải máy chủ.

K — chặn PR kèm bằng chứng. Cảnh báo phải kèm link `.jtl` và dashboard. Không có raw log thì người nhận không phân biệt được hồi quy thật với lỗi môi trường, và cảnh báo sẽ bị bỏ qua.

L → O — đo baseline hai lần trên cùng runner. §2.8 cho thấy tải nền tạo được chênh lệch **10 lần** ở p95 — lớn hơn mọi hiệu ứng khác bài này đo được. Trên CI, mỗi lượt là một runner khác, chạy cùng lúc với job của người khác. Nền baseline **không thể** là "p95 của `main` đo tuần trước": phải đo lại `main` **trong cùng lượt CI, trên cùng runner** với PR, rồi chỉ so **tỉ lệ** giữa hai lần đo đó. Nếu hai lần đo `main` khác nhau quá 20% thì chính runner đang nhiễu → không kết luận gì về PR.

4.3 Trade-off

Trade-off	Chi tiết
Chi phí	Load rút gọn 3 phút + 2 lượt xác nhận = tối đa ~9 phút CI cho một PR chạm backend, cộng ~30 phút/tuần cho lượt Stress theo lịch. Chạy đủ 3 scenario cho mọi commit thì ~30 phút/commit — không ai đợi. Cái phải trả: chỉ Load được tự động hoá theo PR
Báo động giả	Nguồn nhiễu lớn nhất là máy chạy . Bài này đo trên cấu hình load generator và SUT cùng máy ; riêng việc <code>java</code> chạy qua Rosetta thay vì arm64 đã đủ làm sai lệch. Vì thế ngưỡng 20% chứ không phải 5%, và đòi lặp lại 2 lượt. Cái phải trả: hồi quy nhỏ mà thật (10–15%) sẽ lọt
Độ tin của baseline	p95 tuyệt đối không so được giữa hai runner khác cấu hình. Baseline phải là p95 của cùng commit <code>main</code>, cùng runner, cùng lượt CI — mỗi lượt chạy hai lần và chỉ so tỉ lệ. Gấp đôi chi phí, và đó là giá của việc con số có nghĩa
Bỏ sót	Lọc theo <code>backend/</code> bỏ sót ít nhất ba loại hồi quy: (1) frontend gọi API nhiều hơn — tải tăng mà backend không đổi dòng nào; (2) hồi quy chỉ hiện sau 10 phút chạy liên tục, mà lượt 3 phút không thấy; (3) hồi quy do dữ liệu phình chứ không do code. Mục (3) là thứ bài này không chứng minh được — xem §2.8 — nên nó ở đây với tư cách giả thuyết chưa kiểm , không phải phát hiện
Nhiều áp đảo tín hiệu	Trade-off quan trọng nhất, và nó có số đo — cập nhật theo batch được nộp : §2.8 cho thấy <code>load_1m</code> chênh 1,8 lần (3,1 → 5,7) làm p95 chênh 2,6 lần , trong khi tăng VU gấp 10 lần (20 → 200) chỉ làm p95 đi từ 8 lên 18ms , tức 2,25 lần . Nhiều môi trường lớn hơn tín hiệu chủ động tạo ra. §4.4 xác nhận độc lập trên CI: ba lượt giống nhau từng tham số cho p95 101/15/8ms (12,6 lần) . Hệ quả: mọi so sánh tuyệt đối giữa hai lượt CI là vô giá trị; chỉ so tỉ lệ trong cùng một lượt. Cái phải trả: gấp đôi thời gian CI cho mỗi PR

Trade-off	Chi tiết
Ngưỡng đo cái gì	Đo p95, không đo average — §3.2 mục 3: ở Stress p99 gấp 13,0 lần avg (124 vs 9,6ms). Nhưng p95 cũng không bắt được đuôi: max 3.691ms trong khi p95 18ms, gấp 205 lần . Và tỉ lệ p99/avg dẫn theo tải (Load 3,2x → Stress 13,0x), nên chính tỉ lệ đó là chỉ số bảo hoà tốt hơn cả p95 → theo dõi p95, p99 và tỉ lệ p99/avg , chỉ chặn PR theo p95
Perf test tự làm hỏng điều kiện đo của nó	Chính bộ test này đã đẩy <code>products</code> từ ~50k lên 436k dòng. Nếu chạy trong CI mà không dọn, mỗi lượt lại chậm hơn lượt trước vì lý do không liên quan gì tới code → baseline trôi và mọi so sánh mất nghĩa. Bắt buộc: teardown dọn dữ liệu, hoặc restore snapshot DB trước mỗi lượt

4.4 Đã chạy thật trong CI — 6 lượt, và kết quả sửa lại chính §4.3

Mọi thứ ở §4.1–4.3 là **thiết kế trên giấy**, nên nhánh "PR pipeline" được hiện thực thành GitHub Actions thật ([.github/workflows/perf-smoke.yml](#)) và **chạy 6 lượt**: checkout SUT → khởi động → seed qua API → sinh test plan từ cùng một định nghĩa → JMeter non-GUI → **cổng ngưỡng quyết định build đỏ/xanh** ([tools/ci-gate.mjs](#)). Bằng chứng đầy đủ, output nguyên văn: [ci/ci-runs.md](#) .

Runner mọi lượt giống nhau: `Linux x86_64 · 2 vCPU · 7 GB · Node 20 · Java 17 · JMeter 5.6.3 · DB sạch 5 dòng products` . Cùng một file `.jmx` .

#	VU	Ngưỡng p95	Sample	p95	p99	max	Error	Build
1	5	200 ms	785	7	14	728	0%	PASS
2	20	8 ms	2.621	101	1.186	1.879	0%	FAIL
3	5	200 ms	779	8	223	395	0%	PASS
4	20	200 ms	2.646	15	918	2.296	0%	PASS
5	20	200 ms	2.763	8	32	720	0%	PASS

Local để đối chiếu: 20 VU · p95 **8** · p99 **12** · max **84** · 0%.

Điều được xác nhận. Ngưỡng `p95 ≤ 8ms` lấy từ máy local làm build **đỏ thật** trên runner (lượt 2) — cùng plan, cùng SUT, cùng 20 VU, chỉ khác máy. Nút **F/G** của flow chart đứng vững.

Điều bị bác bỏ — và nó là dự đoán của chính §4. Tôi dự đoán runner 2 vCPU sẽ chậm hơn máy 12 lần. Ở **5 VU** nó nhanh **bằng** (7–8ms), tức ngưỡng của local **PASS** và cho **tín hiệu xanh giả**. Rồi tôi rút từ lượt 2 con số "CI chậm hơn local 12,6 lần" — lượt 5 cho **8ms**, đúng bằng local. **Chênh lệch giữa hai máy nhỏ hơn phương sai của chính CI**, nên không quy cho máy được. Đây là lỗi #16, cùng họ lỗi #12, **lần thứ ba** trong bài.

Điều làm thay đổi thiết kế — phát hiện lớn nhất, và tôi không đi tìm nó. Lượt 2, 4, 5 giống nhau từng tham số:

p95 = 101 ms · 15 ms · 8 ms — lệch 12,6 lần giữa hai lượt không khác nhau một tham số nào.

Hệ quả trực tiếp: ngưỡng 8ms làm build **đỏ** ở lượt 2 thì ở lượt 5 **vừa đủ xanh**. Cùng code, cùng ngưỡng, cùng tải. **Một cổng hiệu năng đặt bằng số tuyệt đối trên runner dùng chung là một cổng tung đồng**

xu. Ngay ở 5 VU đuôi cũng thế: p99 **14ms** (lượt 1) so với **223ms** (lượt 3), **16 lần**, trong khi p95 chỉ 7 vs 8.

Điều này **nâng nút I** ("đòi lặp lại được trước khi báo động") từ một bộ lọc phòng xa thành **nút không thể bỏ**: không có nó, lượt 2 sẽ chặn một PR hoàn toàn vô tội. Nó cũng làm ngưỡng 20% ở nút G hoá ra **quá hẹp** — phương sai đo được là 1.160%, nên so tuyệt đối giữa hai lượt CI phải bị **cấm hẳn**, không phải nói ngưỡng.

Và `load_1m` đo lúc **bắt đầu** lượt **không dự báo được** (0,34 → 15ms; 0,88 → 8ms, ngược chiều). Nhiều đến **trong lúc** đo. Bài này **không có** dữ liệu lấy mẫu tài nguyên xuyên lượt trên CI để chỉ ra thủ phạm, nên đây là **chưa biết**, không phải đã giải thích — đúng bài học của §2.8, chỗ mà một cơ chế nghe hợp lý đã được nhận làm nguyên nhân.

Hai thứ ổn định qua cả 6 lượt, và đây là phần dùng được:

- 1. **Error rate 0%** ở mọi lượt, kể cả lượt p95 vọt lên 101ms, và hình dạng phân bố mã trả về giữ nguyên (`200` ~79% · `400` FR-10 ~18% · `403` lockout ~3%).
- 2. **Thứ tự endpoint đắt nhất giữ nguyên** — `import-products` đứng đầu ở cả local (10ms) và CI (166ms ở lượt 2), đúng vì nó là endpoint `INSERT` duy nhất.

→ **Sửa lại đề xuất §4.3**: cổng CI chặn theo **error rate** (mang được qua môi trường) và theo **thứ hạng/tỉ lệ giữa các endpoint trong cùng một lượt** (cũng mang được), **không** theo ngưỡng p95 tuyệt đối (không mang được). Ngưỡng p95 chỉ dùng như **rào chắn thảm họa** đặt rất rộng — 200ms, tức 25 lần baseline — để bắt sự cố sập hẳn, không để bắt hồi quy.

Thêm một điều cổng phải có, học từ lượt 1 và 3: **ngưỡng luôn phải đi kèm mức tải**. Một smoke test 5 VU đi qua đúng cái ngưỡng 8ms mà nó lẽ ra phải chặn; 785 sample là **đủ nhiều**, chỉ là đo ở mức tải sai — nên `--min-samples` không cứu được, phải chốt cả số VU.

Ranh giới: nút nào đã chạy thật, nút nào vẫn là đề xuất

Flow chart §4.1 có 15 nút. Workflow chỉ hiện thực **một nhánh**. Ghi rõ để không ai đọc §4.4 thành "đã dựng xong toàn bộ mô hình":

Nút / cơ chế	Trạng thái	Bằng chứng
Kích hoạt theo <code>push</code> , lọc theo <code>paths</code>	đã chạy thật	3 lượt do <code>push</code> trong <code>ci/ci-runs.md</code>
Chạy plan rút gọn (<code>-Jthreads</code> , <code>-Jduration</code>)	đã chạy thật	6 lượt, 5–20 VU
Cổng ngưỡng p95 + error rate + sản sample, <code>exit 1</code> khi vượt	đã chạy thật	lượt 2 build ĐỎ
Lưu <code>.jtl</code> + HTML dashboard làm artifact, kể cả khi fail (<code>if: always()</code>)	đã chạy thật	artifact <code>perf-smoke-p95-*</code>
F — so p95 từng endpoint với baseline nhánh <code>main</code>	CHƯA — vẫn là đề xuất	workflow không chạy <code>main</code> và PR trong cùng job. Ngưỡng hiện tại là số tuyệt đối truyền vào , không phải so với baseline
L→O — đo baseline hai lần trên cùng runner rồi so tỉ lệ	CHƯA — vẫn là đề xuất	cần 2 lượt/job; chưa dựng

Nút / cơ chế	Trạng thái	Bằng chứng
I — đòi lặp lại được trước khi báo động	CHƯA dừng, nhưng đã được số liệu chứng minh là cần	ba lượt cùng cấu hình cho 101/15/8ms
Chạy Stress theo lịch hằng tuần	CHƯA — vẫn là đề xuất	workflow chỉ có <code>push</code> + <code>workflow_dispatch</code>
Chặn PR kèm comment dẫn link <code>.jtl</code>	CHƯA — vẫn là đề xuất	build đồ thì fail job, chưa comment lên PR

Nói cách khác: phần **đo và chặn** đã chạy thật; phần **so với baseline** — chính là phần §4.4 chứng minh là *bắt buộc phải có* — thì chưa dừng. Đó là việc tiếp theo, không phải việc đã xong.

5. Bug và vấn đề hiệu năng

Chi tiết: [bug-report/bug-report.md](#) · kiểm chứng lại: `bash bug-report/verify-bugs.sh`

#	Loại	Mô tả	Trạng thái
#288	Bảo mật (IDOR) + lệch đặc tả	GET <code>/api/orders/:id</code> không kiểm token → đọc được đơn hàng của bất kỳ ai. Route ngay bên cạnh (<code>/api/orders/my-orders</code>) vẫn trả 401 → là route bị bỏ sót	Xác nhận bằng request thật
#289	Tài liệu thiếu	POST <code>/api/coupon-usage</code> tồn tại, cần token, ghi thật vào <code>coupon_usage</code> , nhưng không có trong <code>api_specification.md</code>	Xác nhận
—	ĐÃ LOẠI	" <code>import-products</code> báo sai số dòng insert" — bác bỏ: 5/5, 60/60, 2/3 đều đúng	Ghi lại kèm bảng kiểm chứng

Vấn đề hiệu năng: không có lỗi nào (0% error ở cả 4 lượt), và **không có suy giảm nào chứng minh được**. Bản báo cáo trước tuyên bố có một suy giảm 2,4–6,4 lần do dữ liệu phình; §2.8 giải thích vì sao tuyên bố đó đã bị chính tôi bác bỏ. Theo §6 mục này *khuyến khích, không bắt buộc*, và báo cáo "không tìm thấy, kèm lý do vì sao phép đo chưa đủ để kết luận" trung thực hơn là giữ một phát hiện không đúng được.

Điều **đo được** và đáng ghi: ở 200 VU / 564 req/s, `node` tiêu **98,4% của một lõi** trong khi máy còn 11 lõi rảnh. Đó là trần kiến trúc (một luồng JS), không phải trần phần cứng.

6. Giới hạn của bài đo này

Năm giới hạn, xếp theo mức ảnh hưởng tới kết luận:

- Tải nền của máy không được kiểm soát.** §2.8 chứng minh đây là biến **áp đảo** bằng ba điểm dữ liệu: `load_1m` 5,2 / 3,1 / 5,7 → p95 Stress 26 / 7 / 18 ms. Chênh 1,8 lần tải nền tạo ra chênh 2,6 lần p95, trong khi tăng VU gấp 10 lần chỉ tạo chênh 2,25 lần. Lúc đo vẫn có 4 container Docker, VS Code, Chrome và một tiến trình AI agent chạy song song. Mọi con số trong báo cáo chỉ có nghĩa **kèm điều kiện `load_1m` ≈ 4,4–6,0**.
- Load generator và SUT chạy trên cùng một máy.** JMeter tiêu CPU đỉnh **118–183%** ở cả 4 lượt — nhiều hơn `node` ở ba lượt. Một phần latency đo được là chi phí của chính JMeter.

3. **Mật khẩu lưu plaintext, so sánh bằng ===** (`server.js:46`). Không có bcrypt/argon2 nên login không tốn CPU lắm. p95 24ms của `POST /api/login` ở 200 VU **không** đại diện cho hệ thống băm mật khẩu đúng cách.
4. **Bước 5 chỉ ghi thật 400 lần mỗi lượt**; 99,2% sample ở Stress trả 400 do FR-10 chặn trước lệnh `UPDATE`. p95 14ms của bước 5 **không** đại diện cho chi phí ghi — tín hiệu đó ở bước 4.
5. **Đỉnh RSS 1373 MB ở Stress chưa giải thích được** (§2.5). Hai mẫu trên 230, dưới 4 giây. Không đủ để kết luận, và tôi không gán nguyên nhân.

6.1 Nếu làm lại, tôi đổi ba thứ

Đổi gì	Vì sao
Đóng mọi ứng dụng khác, ghi <code>load_1m</code> trước/sau, chỉ so lượt có tải nền tương đương	§2.8 — tương quan mạnh nhất đo được, và tôi đã suýt công bố một kết luận nhân quả sai vì bỏ qua nó
Restore snapshot DB trước mỗi lượt	<code>products</code> trôi từ 5 lên 830.139 dòng do chính bộ test ; không cô lập được biến này thì không trả lời được câu hỏi về kích thước dữ liệu
Tách load generator sang máy khác	JMeter và <code>node</code> tiêu CPU xấp xỉ nhau ở Stress, nên không tách được chi phí của hai bên